Trabajo Práctico Nro. 3: Algoritmos de Vectores de Soporte

Ezequiel Agustin Perez, Gonzalo Nahuel Baliarda, Lucas Agustin Vittor

Instituto Tecnológico de Buenos Aires

{*eperez, gbaliarda, lvittor*}*@itba.edu.ar*

11 de octubre de 2023

Ejercicio 1

Enunciado

1. Construir un dataset linealmente separable y usar un perceptrón simple para clasificarlo
2. Obtener el hiperplano óptimo a partir del hiperplano del perceptrón
3. Construir un dataset con ejemplos mal clasificados y usar un perceptrón simple para clasificarlo
4. Clasificar los dataset con SVM

Dataset 1

Randomizado y dividido en 80 % train, 20 % test.

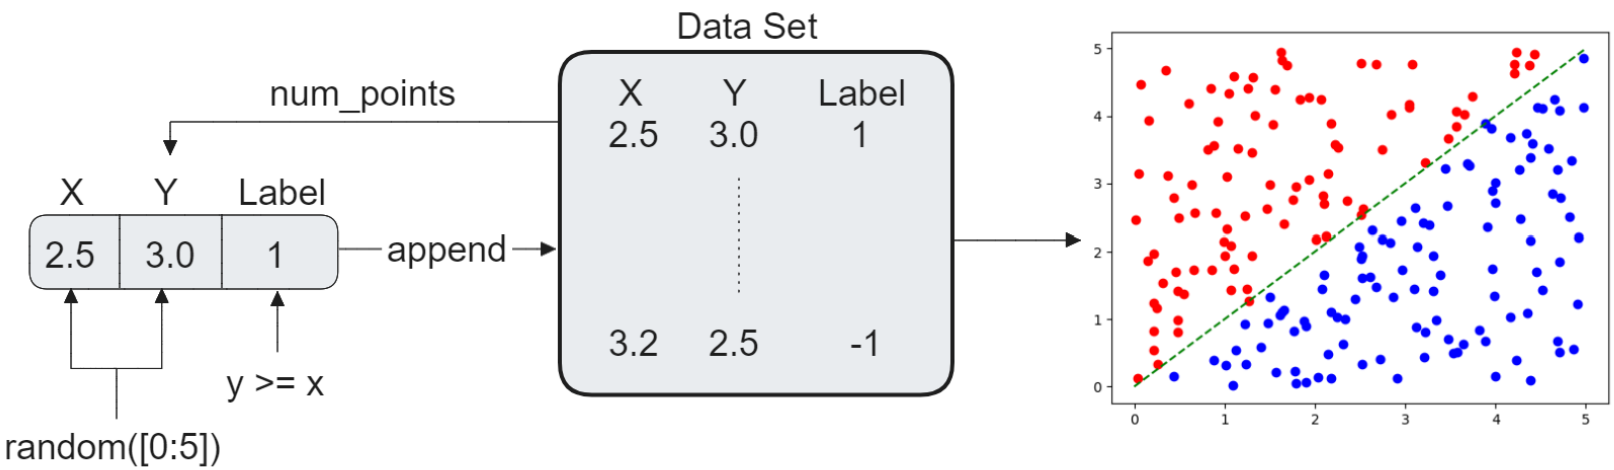

Dataset 2

Randomizado y dividido en 80 % train, 20 % test.

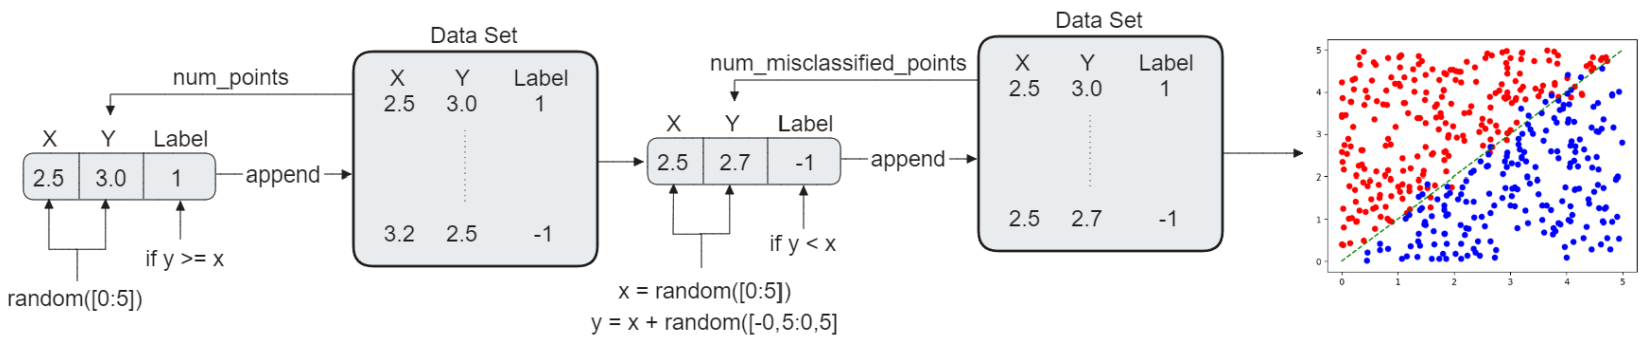

Datasets

- TP3-1: 200 puntos
- TP3-2: 400 puntos bien clasificados y 40 puntos clasificados aleatoriamente.

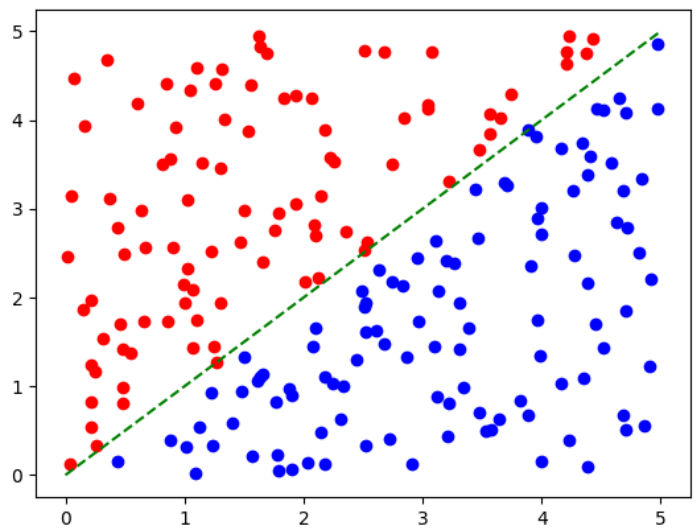

Figura: TP3-1

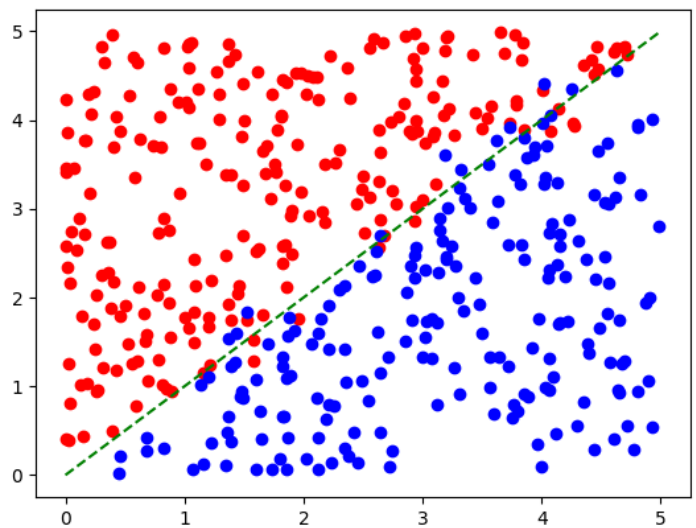

Figura: TP3-2

Perceptrón Simple: modelo

Aprendizaje

$$w_i^{nuevo} = w_i^{viejo} + \Delta w_i \quad \text{con } \Delta w_i = 2\eta\xi_i^\mu\zeta_i^\mu$$

Función escalón

$$f(x) = \begin{cases} 1 & x \geq 0 \\ -1 & sino \end{cases}$$

Momentum

$$\Delta = \Delta + \mu * \Delta_{prev}$$

Perceptrón Simple: implementación

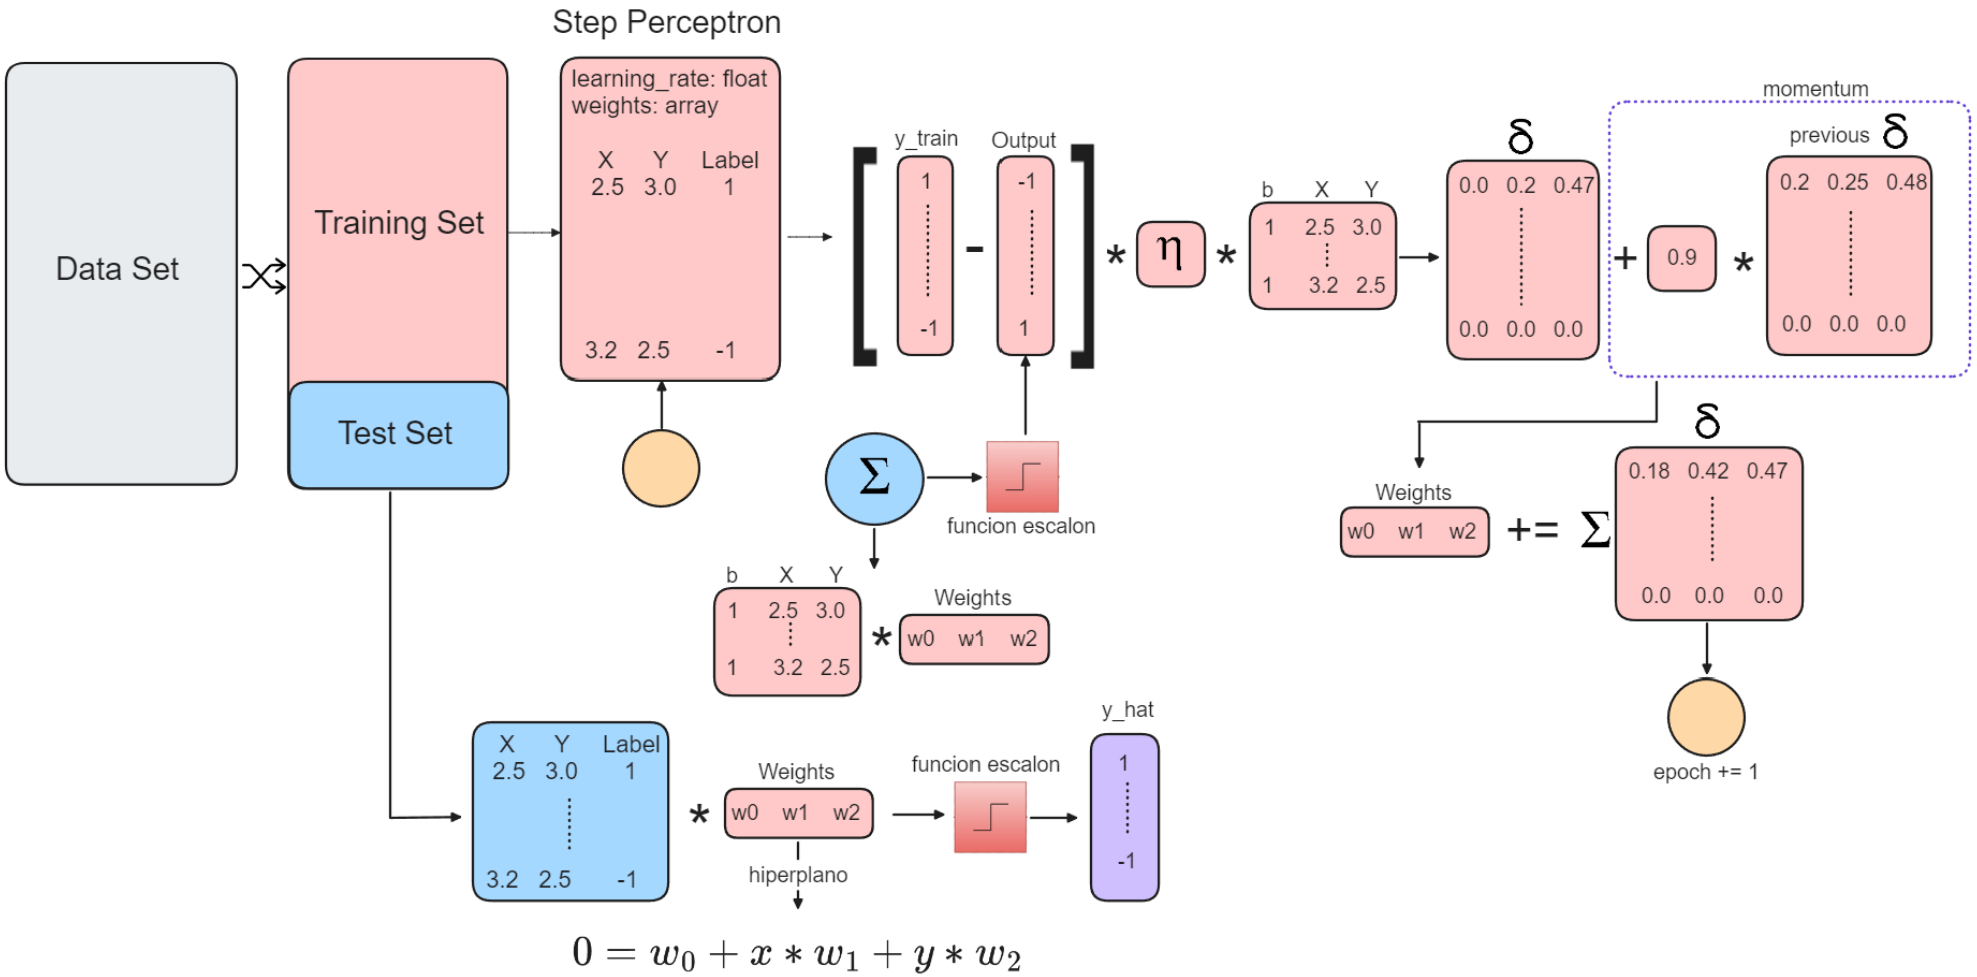

SVM: modelo

Hinge Loss

$$l = \frac{1}{2}w^2 + \Sigma[y_i(wx_i + b)]$$

Gradiente descendente

$$w = \begin{cases} w + C\Sigma_{i=1}^{p}(-1)y_i x_i & t < 1 \\ w + C\Sigma_{i=1}^{p}0 = w & t \geq 1 \end{cases}$$

$$b = \begin{cases} C\Sigma_{i=1}^{p}(-1)y_i & t < 1 \\ C\Sigma_{i=1}^{p}0 = 0 & t \geq 1 \end{cases}$$

SVM: implementación

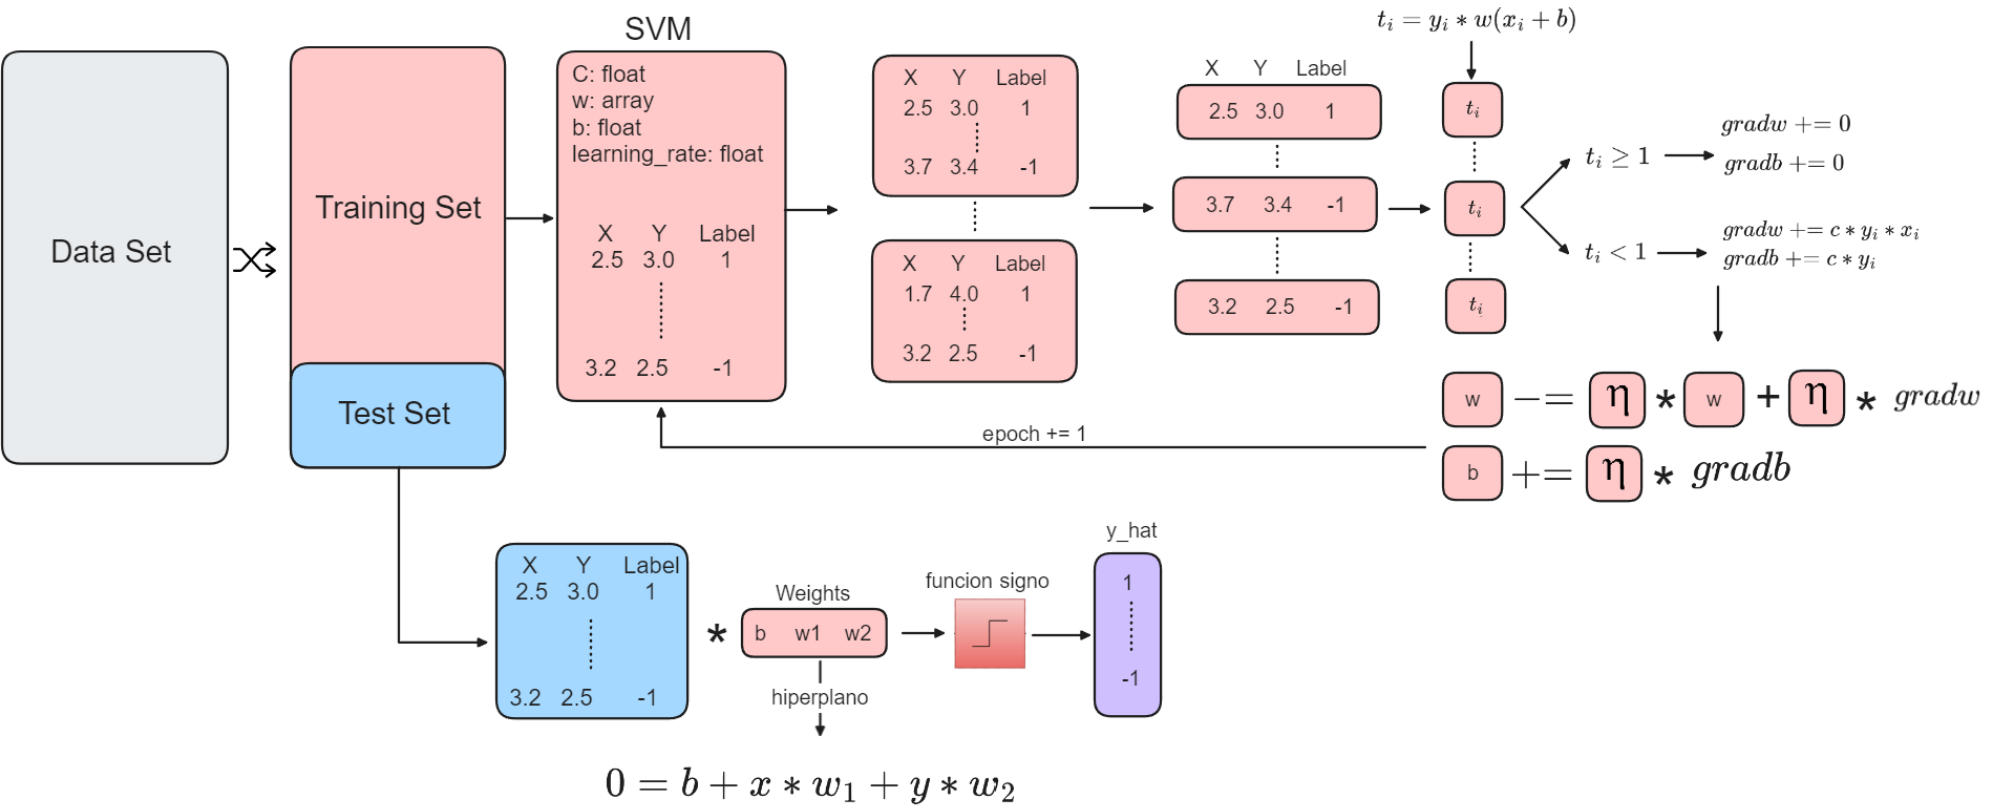

Resultados: entrenamiento perceptrón

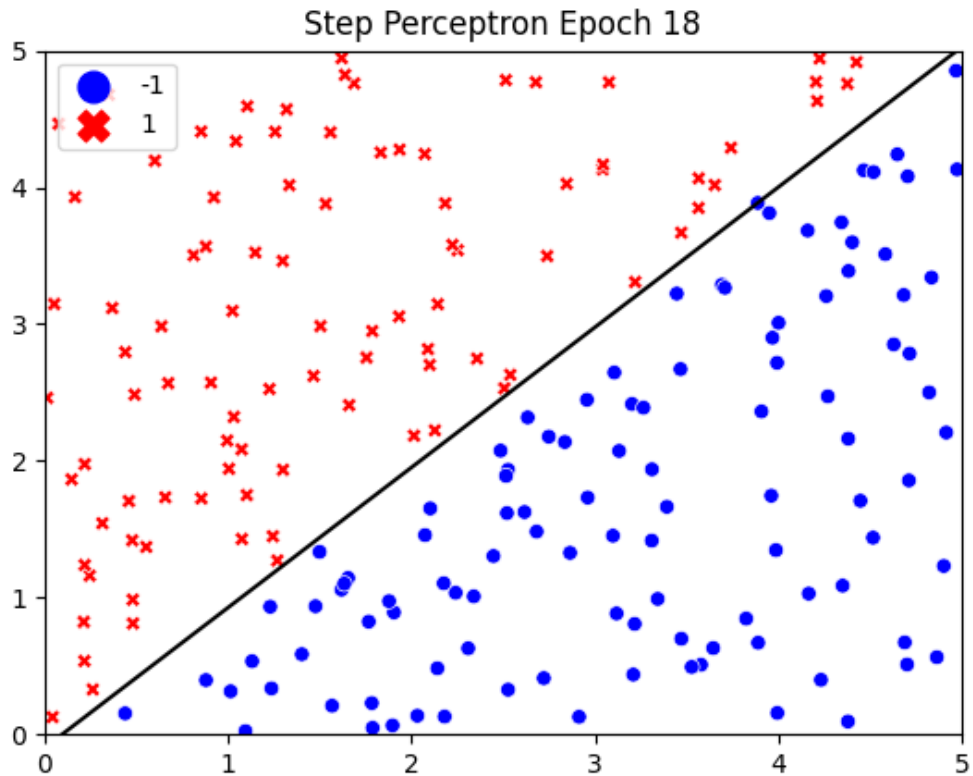

Figura: Step Perceptron

GIF

Resultados: hiperplano óptimo

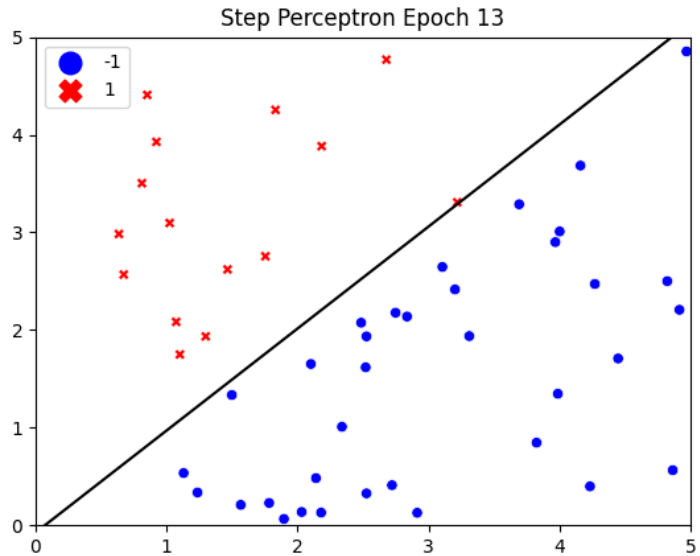

Figura: Inicio

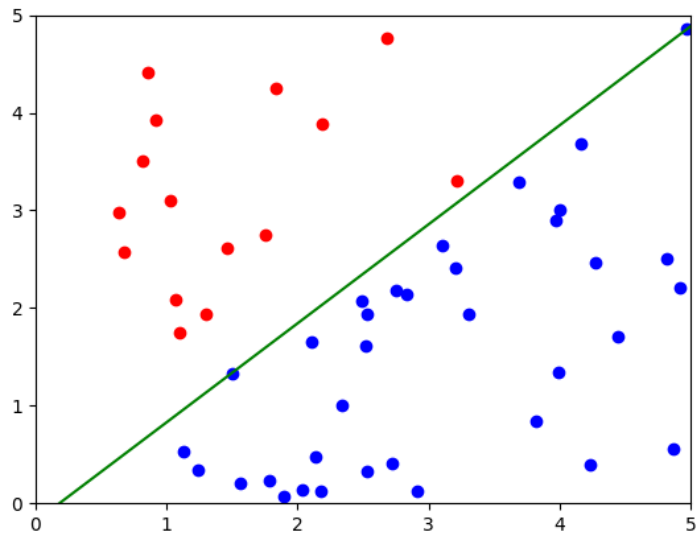

Figura: Dirección

Resultados: hiperplano óptimo

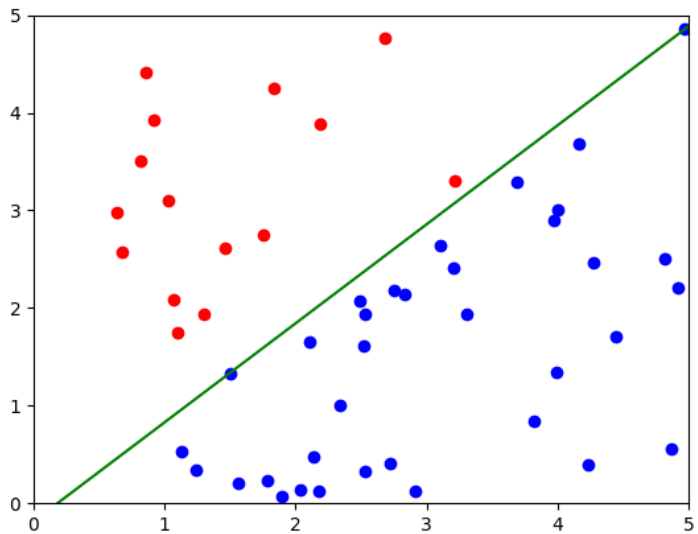

Figura: Dirección

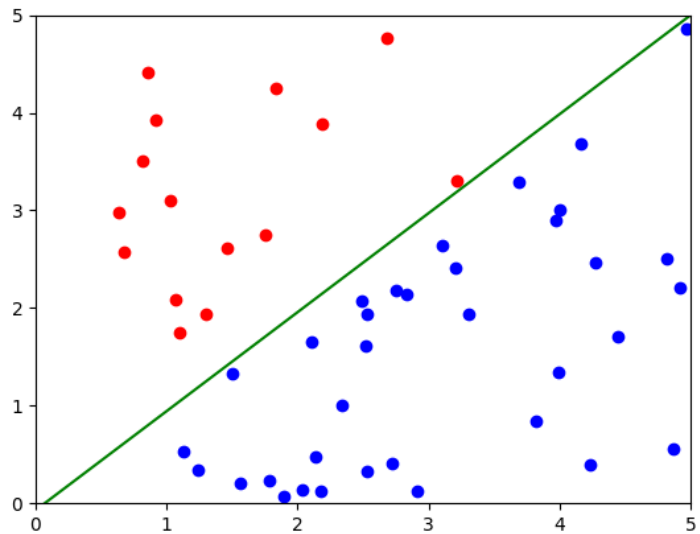

Figura: Traslación

Resultados: test perceptron

- $\eta = 0.1$; $\mu = 0{,}9$; epochs $= 50$

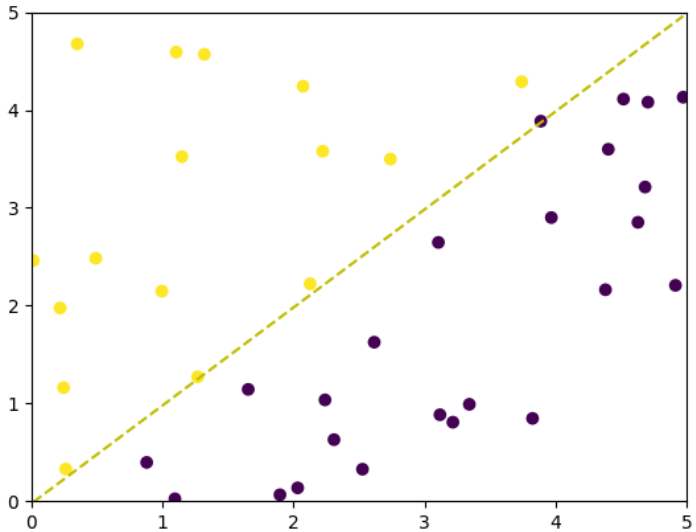

Figura: Test TP3-1

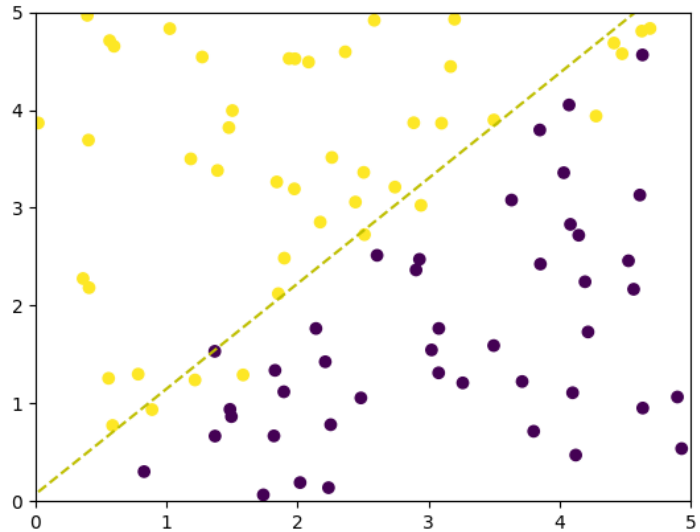

Figura: Test TP3-2

Resultados: test SVM

- C = 2 ; $\eta = 0.001$; epochs = 1000

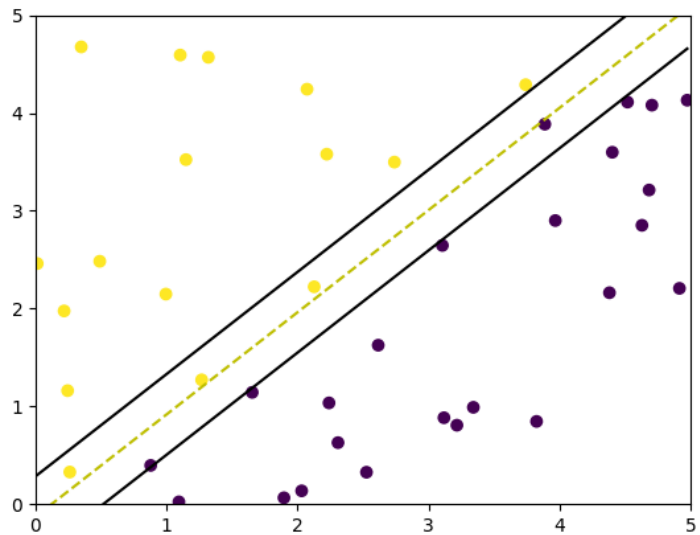

Figura: Test TP3-1

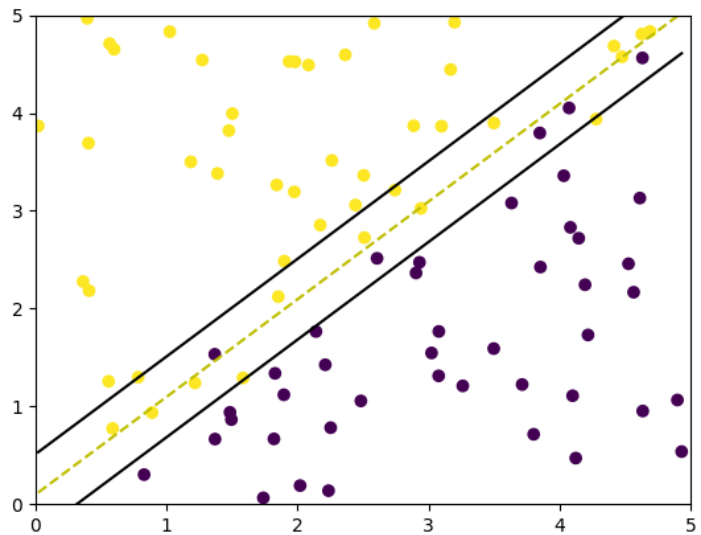

Figura: Test TP3-2

Resultados: precisión sobre testing set

- Mismos parámetros anteriores.
- 10 experimentos ; error = std.

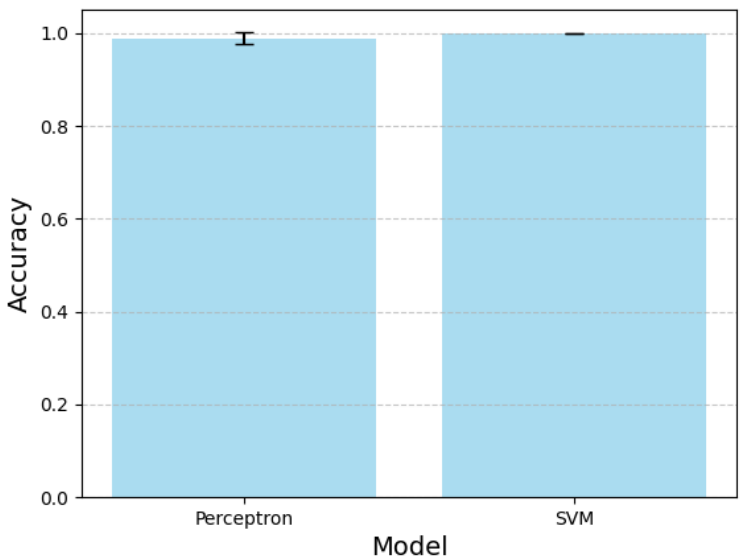

Figura: Precisión TP3-1

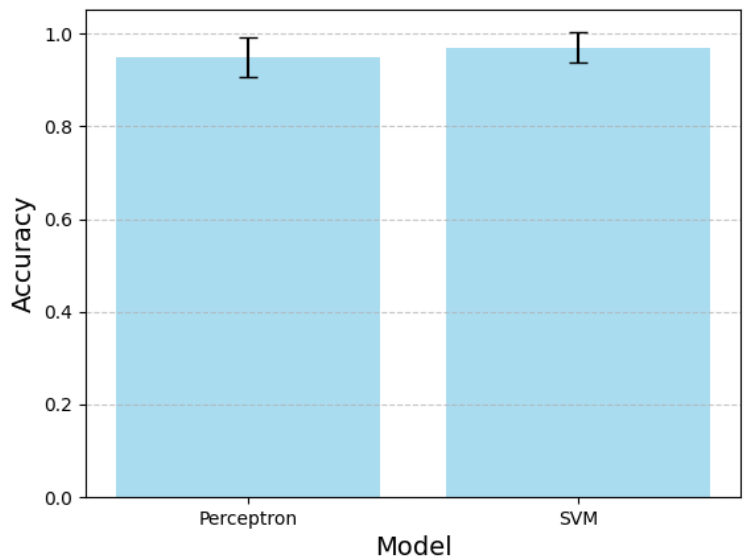

Figura: Precisión TP3-2

Conclusiones

- SVM logra una mayor precisión que el perceptrón escalón.
- Para el dataset linealmente separable, la diferencia de precisión es ínfima.

Ejercicio 2

Enunciado

A partir de las imagenes dadas:

1. Crear conjunto de entrenamiento (imagenes a pixeles)
2. Dividir dataset en training y testing set.
3. Aplicar hyperparameter tunning para SVM. Agregar matrices de confusion.
4. Colorear *cow.jpg* usando SVM y 3 colores.
5. Clasificar todos los pixeles de *cow.jpg*
6. Clasificar todos los pixeles de otra imagen

Dataset

- Tomamos cada imagen en formato RGB
- Hacemos un resize de la imagen
- Pasamos la imagen a un vector donde cada elemento es de la forma (R, G, B)

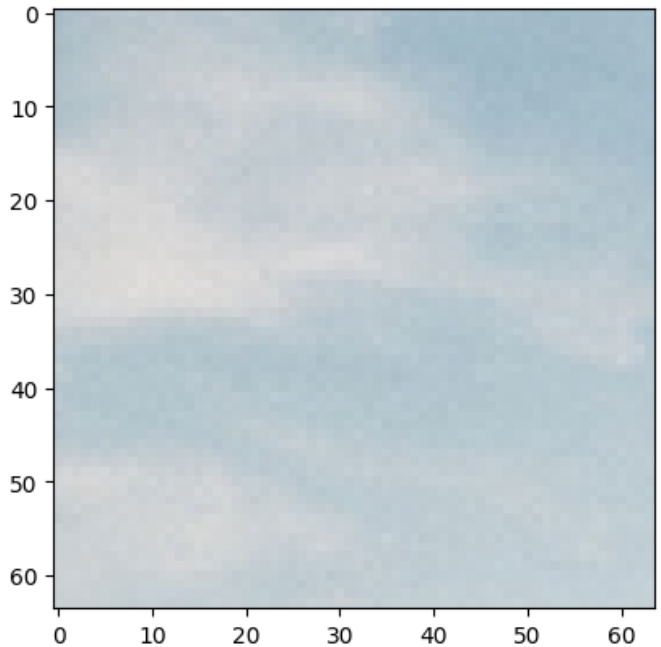

Dataset

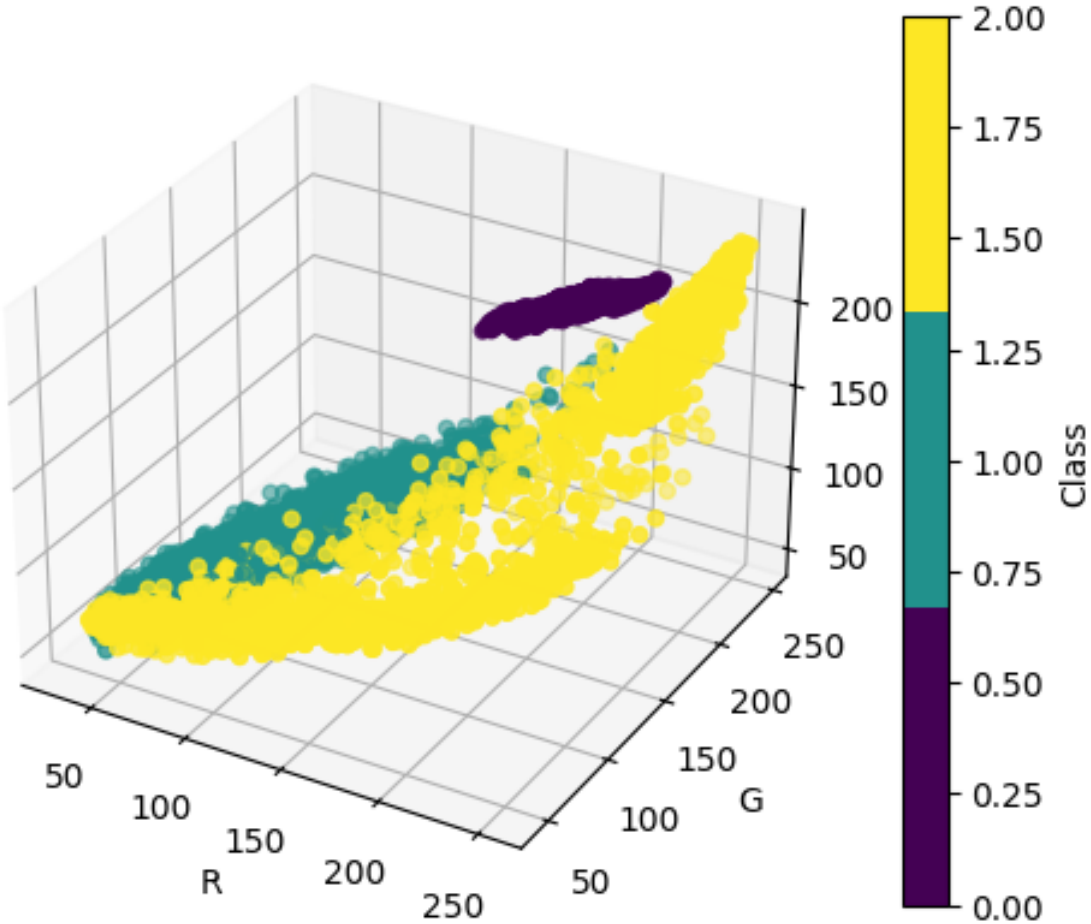

Figura: Visualización de los datos

SVM: kernels

- Nos permitirán crear clasificadores no lineales.

Kernel radial:

$$poly(x_i, x_j) = (x_i \cdot x_j + r)^d$$

Kernel polinómico:

$$rbf(x_i, x_j) = e^{-\gamma ||x_i - x_j||^2}$$

SVM: kernels

- El kernel radial transforma los datos a un espacio de dimensión infinita, mientras que el polinómico los transforma a uno de dimension específica dada por el grado del polinomio.
- El kernel radial es más flexible y puede manejar patrones más complejos.

Búsqueda de hiperparámetros

- GridSearchCV ($scoring = accuracy$, $cv = 5$)

kernel *poly*
degree $[2, 3, 4]$
C $[0{,}1, 1, 10, 100]$

kernel *rbf*
gamma $[10^{-5}, 10^{-4}, 10^{-3}, 10^{-2}]$
C $[0{,}1, 1, 10, 100]$

Parámetros óptimos

- 28 combinaciones analizadas (5 folds por cada una).

kernel	*rbf*
gamma	10^{-4}
C	10,0

- *accuracy* = 0,9901322482197354.

Matriz de confusión (testing set)

Kernel: poly, degree: 2, C: 1.0

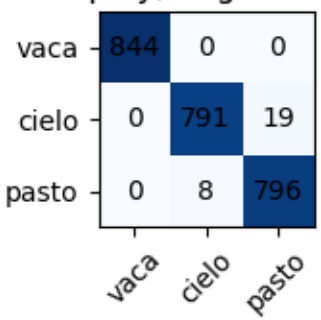

Kernel: poly, degree: 3, C: 1.0

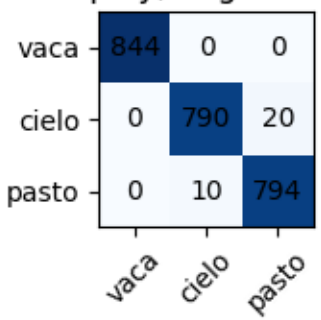

Kernel: poly, degree: 4, C: 1.0

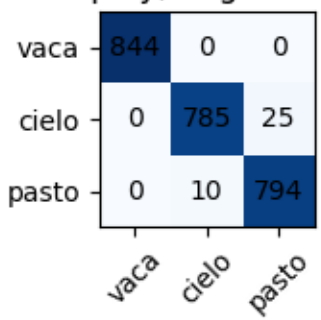

Kernel: rbf, gamma: 1e-05, C: 1.0

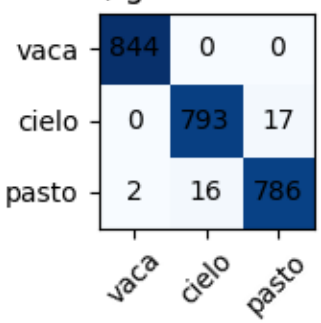

Kernel: rbf, gamma: 0.0001, C: 1.0

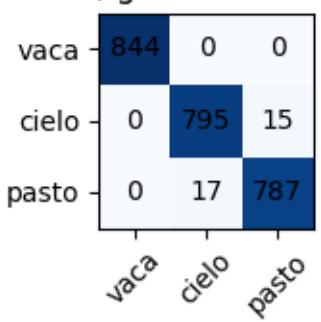

Kernel: rbf, gamma: 0.001, C: 1.0

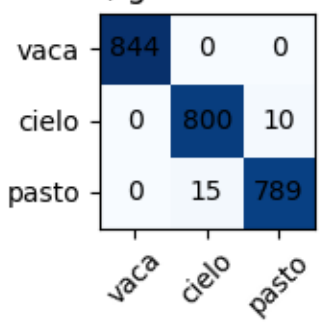

Kernel: poly, degree: 2, C: 10.0

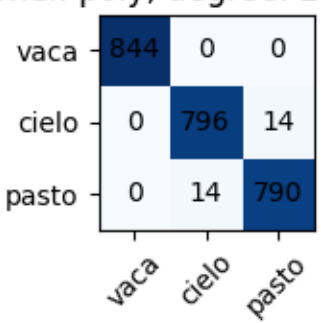

Kernel: poly, degree: 3, C: 10.0

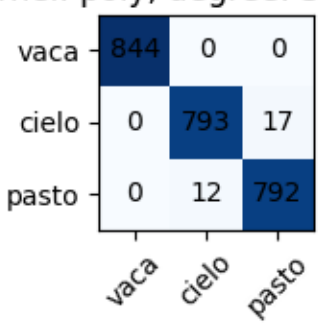

Kernel: poly, degree: 4, C: 10.0

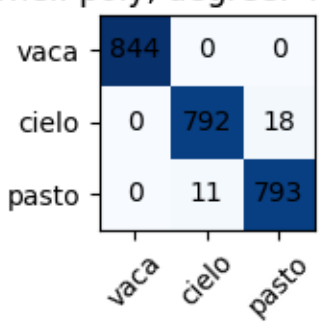

Colores

Cielo	Blanco $(255, 255, 255)$
Pasto	Negro $(0, 0, 0)$
Vaca	Gris $(127, 127, 127)$

Resultados

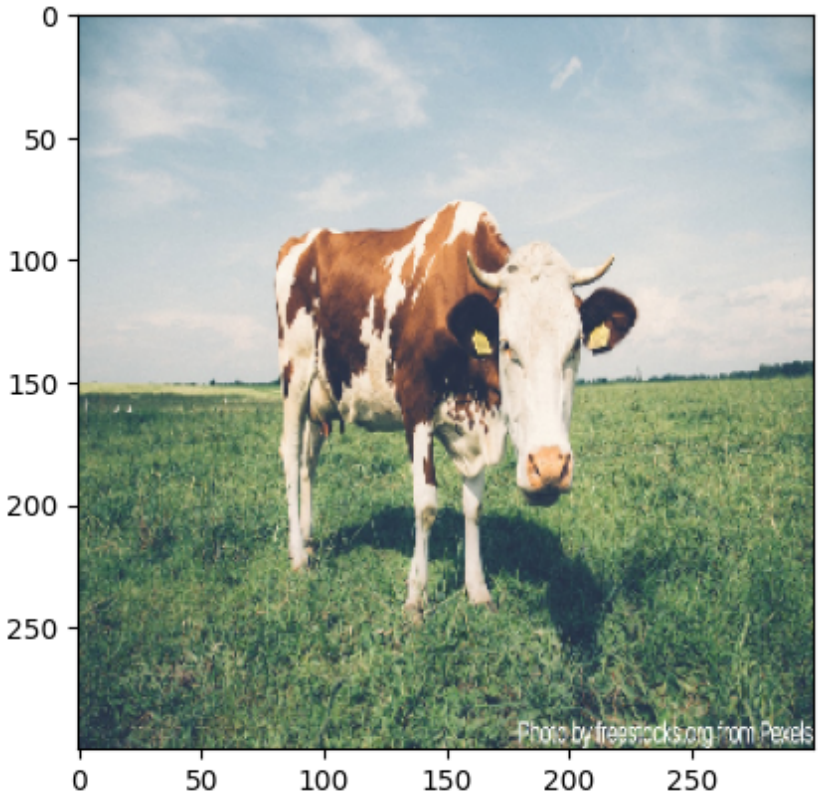
0
50
100
150
200
250
0
50
100
150
200
250

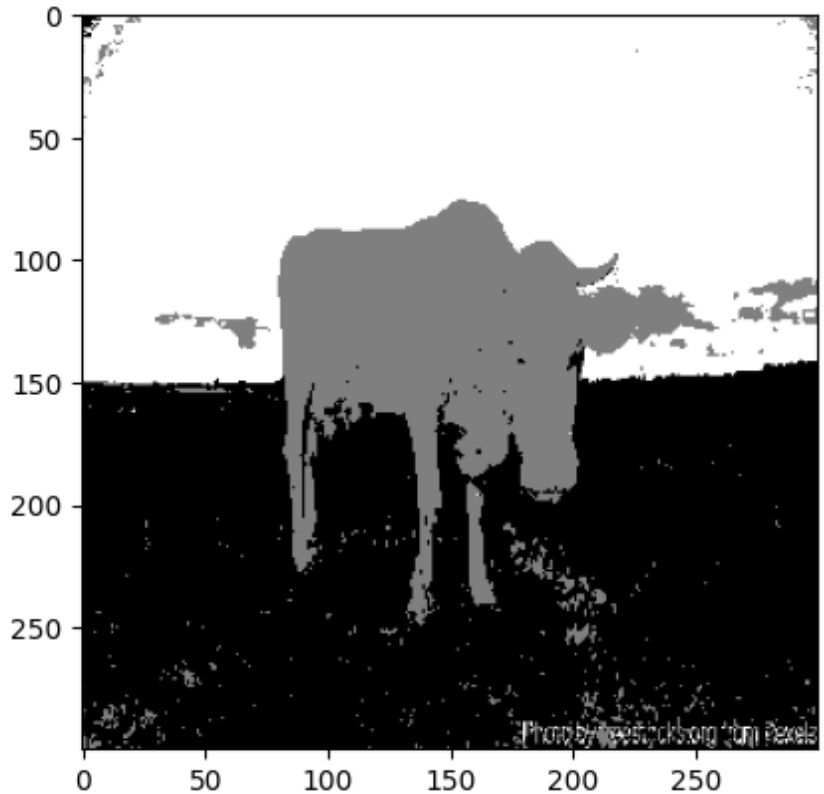
0
50
100
150
200
250
0
50
100
150
200
250

Resultados

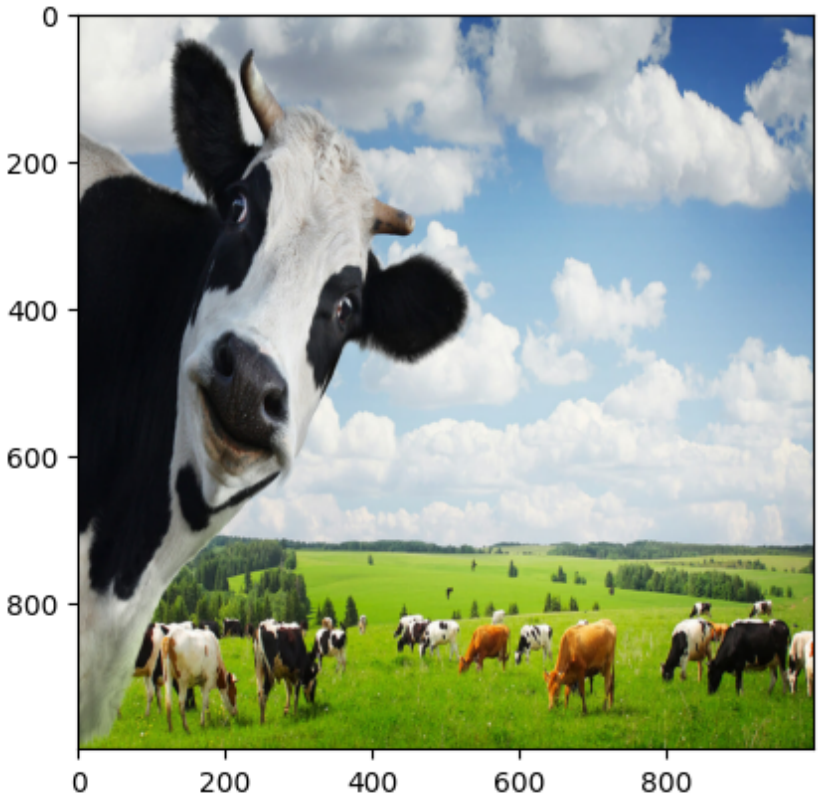
0
200
400
600
800
0
200
400
600
800

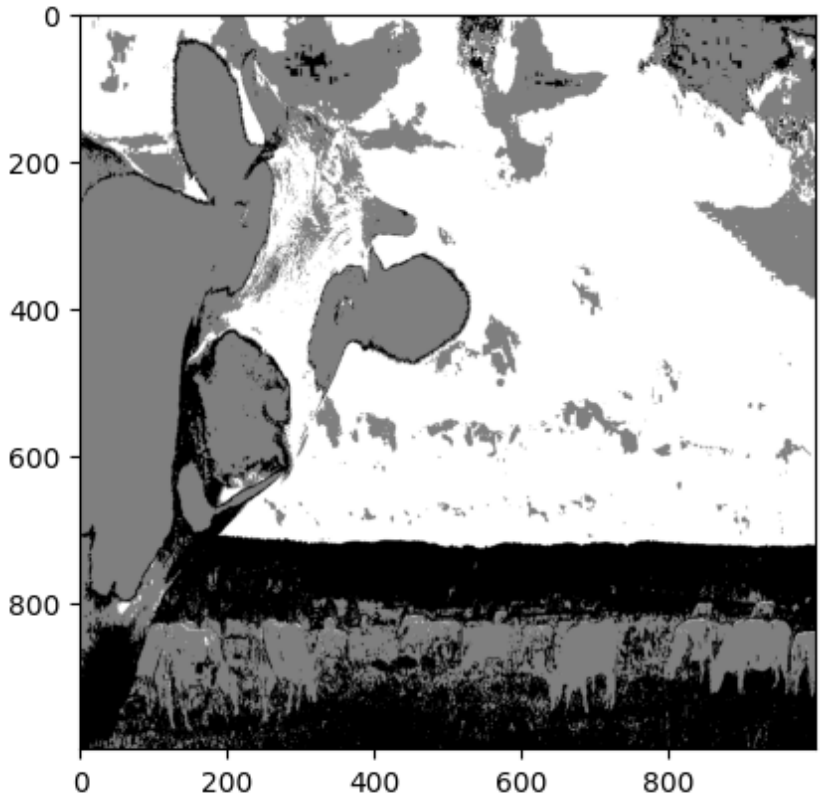
0
200
400
600
800
0
200
400
600
800

Conclusiones

- No se apreciaron grandes cambios en la precisión del modelo al variar los hiperparámetros en los rangos propuestos.
- La precisión del modelo sobre una imagen nueva no fue del todo buena.

Reflexiones

- Como el conjunto de entrenamiento era escaso (3 fotos), podriamos haber hecho data augmentation (rotar las imagenes, zoom in, zoom out, cambiar de RGB a CMYK, cambiar brillo de la imagen, etc).
- Grid search para ajustar hiperparámetros es bastante costoso en general, pero para nuestro caso fue util por la poca cantidad de hiperparametros a probar.
- Hubiese sido interesante separar la data en training, validation y test sets.

Muchas gracias